

**UNIVERSIDADE FEDERAL DA FRONTEIRA SUL
CAMPUS CHAPECÓ
CURSO DE CIÊNCIA DA COMPUTAÇÃO**

LUAN BORTOLI

**APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NA
PREDIÇÃO DE DOENÇAS CARDIOVASCULARES:
UMA ABORDAGEM BASEADA EM APRENDIZADO DE
MÁQUINA**

**CHAPECÓ
2025**

LUAN BORTOLI

**APLICAÇÃO DE INTELIGÊNCIA ARTIFICIAL NA
PREDIÇÃO DE DOENÇAS CARDIOVASCULARES:
UMA ABORDAGEM BASEADA EM APRENDIZADO DE
MÁQUINA**

Trabalho de Conclusão de Curso apresentado ao
Curso de Ciência da Computação da Universidade
Federal da Fronteira Sul (UFFS), como requisito
para obtenção do título de Bacharel em Ciência
da Computação.

Orientador: Prof. Dr. Giancarlo Dondoni Salton

**CHAPECÓ
2025**

RESUMO

Este estudo aborda a aplicação de Inteligência Artificial para a predição de doenças cardiovasculares, que representam um significativo desafio de saúde global. O objetivo principal é desenvolver e avaliar um modelo preditivo de alta acurácia utilizando algoritmos de aprendizado de máquina aplicados a dados integrados de exames médicos. A metodologia baseia-se em um estudo experimental e quantitativo, empregando a base de dados pública MIMIC-IV. O processo inclui o pré-processamento dos dados, seguido pela implementação, treinamento e avaliação comparativa de algoritmos supervisionados, como Regressão Logística, *Support Vector Machine*, Árvores de Decisão e *K-Nearest Neighbors*. Serão aplicadas técnicas de interpretabilidade para elucidar a relevância dos atributos clínicos na decisão dos modelos. O desempenho será mensurado por métricas como acurácia, precisão, *recall*, *F1-Score* e a curva ROC, com o uso da estratégia de validação cruzada. Os resultados esperados visam contribuir para a identificação precoce de indivíduos em risco e oferecer uma ferramenta de apoio à decisão clínica confiável e explicável.

Palavras-Chave: Aprendizado de Máquina, Doenças Cardiovasculares, Inteligência Artificial, Predição.

ABSTRACT

This study addresses the application of Artificial Intelligence for the prediction of cardiovascular diseases, which represent a significant global health challenge. The main objective is to develop and evaluate a highly accurate predictive model using machine learning algorithms applied to integrated medical examination data. The methodology is based on an experimental and quantitative study, employing the public database MIMIC-IV. The process includes data preprocessing, followed by the implementation, training, and comparative evaluation of supervised algorithms such as Logistic Regression, Support Vector Machine, Decision Trees, and K-Nearest Neighbors. Interpretability techniques will be applied to elucidate the relevance of clinical attributes in the models' decision-making. Performance will be measured by metrics such as accuracy, precision, recall, F1-Score, and the ROC curve, using a cross-validation strategy. The expected results aim to contribute to the early identification of individuals at risk and offer a reliable and explainable clinical decision support tool.

Keywords: Machine Learning, Cardiovascular Diseases, Artificial Intelligence, Prediction.

SUMÁRIO

1	INTRODUÇÃO	5
1.1	PROBLEMA	6
1.2	OBJETIVOS	6
1.2.1	OBJETIVO GERAL	6
1.2.2	OBJETIVOS ESPECÍFICOS	6
1.3	JUSTIFICATIVA	7
2	FUNDAMENTAÇÃO TEÓRICA	8
2.1	DOENÇAS CARDIOVASCULARES	8
2.1.1	CLASSIFICAÇÃO DAS DOENÇAS CARDIOVASCULARES	9
2.1.2	FATORES DE RISCO	10
2.1.3	ANÁLISE DOS PRINCIPAIS FATORES DE RISCO MODIFICÁVEIS	10
2.2	FUNDAMENTOS DA INTELIGÊNCIA ARTIFICIAL	12
2.2.1	CARACTERÍSTICAS FUNDAMENTAIS DA INTELIGÊNCIA ARTIFICIAL	12
2.3	<i>MACHINE LEARNING</i>	12
2.4	ALGORITMOS DE <i>MACHINE LEARNING</i>	13
2.4.1	REGRESSÃO LOGÍSTICA	13
2.4.2	<i>SUPPORT VECTOR MACHINE</i>	15
2.4.3	ÁRVORES DE DECISÃO	16
2.4.4	<i>K-NEAREST NEIGHBORS</i>	17
3	TRABALHOS RELACIONADOS	19
3.1	LACUNA DE PESQUISA	22
4	METODOLOGIA	24
5	CRONOGRAMA	29
	REFERÊNCIAS	30

1. INTRODUÇÃO

As doenças cardiovasculares (DCV) representam uma das principais causas de mortalidade em âmbito global, constituindo um desafio significativo para os sistemas de saúde pública mundial. A Organização Mundial da Saúde (OMS) apontou que as DCV são responsáveis por um número alarmante de óbitos anuais, cerca de 19,8 milhões de pessoas em 2022, que poderiam ser prevenidos, e que, por si só, contribuem para uma sobrecarga dos sistemas de saúde. De acordo com a OMS, cerca de 32% das mortes que ocorreram foram relacionadas as DCV, e dessas mortes, 85% foram causadas por infarto e acidente vascular cerebral (AVC) (Organização Mundial da Saúde, 2025). As DCV poderiam ser prevenidas, pois, na maioria dos casos, estão interligadas a fatores de risco previamente conhecidos, como, por exemplo, o uso de tabaco, alimentação não-saudável, excesso de sal, açúcar e gorduras, obesidade, sedentarismo, consumo excessivo de álcool, entre outros (Organização Mundial da Saúde, 2025).

Diante desses fatos, pode-se afirmar que o aprimoramento de métodos para o diagnóstico precoce e a estratificação de risco das DCV é fundamental para a implementação de intervenções clínicas mais eficazes. A identificação antecipada de indivíduos com maior probabilidade de desenvolver essas doenças permite a adoção de medidas direcionadas, capazes de modificar a trajetória clínica do processo patológico, reduzir complicações e melhorar a qualidade de vida dos pacientes.

O avanço da tecnologia, em especial da Inteligência Artificial (IA) e do Aprendizado de Máquina (*Machine Learning*), tem mudado a forma de trabalhar em inúmeras áreas, incluindo a medicina. A capacidade dos algoritmos de IA de analisarem grandes volumes de dados complexos com velocidade e precisão superiores a capacidade humana abre novas vertentes para diagnósticos médicos mais precisos e rápidos (CHANG et al., 2022). Na cardiologia, a aplicação de modelos de Aprendizado de Máquina para analisar dados provenientes de exames médicos, como eletrocardiograma (ECG), exames laboratoriais e dados clínicos, tem se mostrado uma abordagem promissora para a predição de doenças cardiovasculares, oferecendo uma ferramenta de apoio à decisão clínica de grande potencial (SINGH et al., 2024).

1.1 Problema

Os métodos tradicionais de diagnóstico de doenças cardiovasculares, embora bem estabelecidos e consolidados, frequentemente dependem da interpretação subjetiva de exames e da análise de um número limitado de fatores de risco, o que pode levar a diagnósticos tardios ou imprecisos. A análise manual de múltiplos exames é um processo demorado e suscetível a falhas, e a integração de dados de múltiplos exames para construir um quadro clínico mais abrangente pode representar uma dificuldade adicional para os profissionais da saúde. Além disso, métodos estatísticos convencionais nem sempre conseguem identificar relações mais complexas ou padrões sutis presentes nos dados biológicos, o que pode limitar sua precisão diagnóstica (CORREIA et al., 2021).

Diante do cenário exposto, surge a seguinte indagação: Como a inteligência artificial pode ser utilizada para desenvolver um modelo preditivo para doenças cardiovasculares, a partir da análise integrada de dados de exames médicos, visando aprimorar a precisão diagnóstica e possibilitar intervenções mais rápidas e eficazes?

1.2 Objetivos

1.2.1 Objetivo Geral

Desenvolver e avaliar um modelo de inteligência artificial para a predição de doenças cardiovasculares, empregando algoritmos de aprendizado de máquina aplicados a dados provenientes de exames médicos disponibilizados em bases de dados públicas e científicas.

1.2.2 Objetivos Específicos

- Realizar revisão da literatura sobre técnicas de Inteligência Artificial e Aprendizado de Máquina aplicadas à predição de doenças cardiovasculares;
- Implementar, treinar e comparar o desempenho de diferentes algoritmos de aprendizagem de máquina;

- Avaliar a performance dos modelos desenvolvidos utilizando métricas de avaliação consolidadas;
- Identificar e determinar os atributos mais relevantes para a predição de doenças cardiovasculares com base no modelo de melhor desempenho e em técnicas de interpretabilidade

1.3 Justificativa

A relevância desta pesquisa se manifesta em diversas dimensões, sendo estas do ponto de vista científico, social e tecnológico. Do ponto de vista científico, o estudo contribui para a crescente área de aplicação da IA na saúde, validando e comparando diversas abordagens algorítmicas em um contexto clínico altamente relevante. A análise aprofundada de *datasets* como o *Medical Information Mart for Intensive Care IV* (MIMIC-IV) pode gerar novas percepções sobre os fatores preditivos de doenças cardiovasculares.

Do ponto de vista social, o desenvolvimento de uma ferramenta de diagnóstico preditivo de alta acurácia tem o potencial de impactar positivamente a saúde pública. Ao permitir a identificação precoce de indivíduos em risco, o modelo pode facilitar a adoção de medidas preventivas, reduzir a necessidade de hospitalizações e salvar vidas. Nesse sentido, a adoção de modelos preditivos pode otimizar o uso de recursos nos sistemas de saúde, ao permitir intervenções mais precisas e reduzir a demanda por procedimentos complexos e de maior custo.

Sob a perspectiva tecnológica, o projeto abrange a aplicação prática de algoritmos de aprendizado de máquina e a estruturação de um fluxo de trabalho completo para o tratamento, processamento e análise de dados médicos. A viabilidade técnica é reforçada pela ampla disponibilidade de ferramentas *open-source*, como *Python*, *Scikit-Learn* e *TensorFlow*, que oferecem robustez para a experimentação e implementação de modelos preditivos. Além disso, o estudo se beneficia da existência de *datasets* públicos de alta qualidade, como o MIMIC-IV, que é amplamente adotado na literatura deste projeto.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Doenças Cardiovasculares

As doenças cardiovasculares englobam um conjunto de distúrbios que afetam o coração e os vasos sanguíneos, representando a principal causa de morbidade e mortalidade em escala global. Essas patologias podem ser classificadas em diferentes grupos, conforme sua origem e manifestação clínica. Entre as doenças, podem ser citadas a doença arterial coronariana, a doença cerebrovascular, a doença arterial periférica, a doença cardíaca reumática, a doença cardíaca congênita, a trombose venosa profunda e a embolia pulmonar. A Organização Mundial da Saúde estima que as DCVs são responsáveis por quase 18 milhões de mortes por ano, o que corresponde a mais de 30% de todos os óbitos no mundo. É alarmante notar que mais de três quartos dessas fatalidades ocorrem em países de baixa e média renda, evidenciando uma forte correlação entre determinantes socioeconômicos e o desfecho clínico (Organização Mundial da Saúde, 2025; Organização Pan-Americana de Saúde, 2025).

A carga epidemiológica das DCV tem demonstrado uma transição significativa nas últimas décadas. Historicamente associadas predominantemente a países de alta renda, essas doenças emergiram como o maior desafio de saúde pública também nas nações em desenvolvimento. Um estudo epidemiológico focado em países de língua portuguesa revelou uma mudança drástica no cenário de mortalidade. Enquanto em 1990 as DCV lideravam os óbitos apenas no Brasil e em Portugal; em 2016, elas já ocupavam essa posição também em outros países como Cabo Verde, São Tomé e Príncipe e Timor-Leste (NASCIMENTO et al., 2018).

Entre as diversas manifestações clínicas, destacam-se a doença arterial coronariana, a insuficiência cardíaca (IC), arritmias como a fibrilação atrial (FA), a doença cerebrovascular (AVC), a doença arterial periférica, a cardiopatia reumática e a trombose venosa profunda. No contexto clínico, a doença arterial coronariana assume relevância crítica devido à sua associação direta com eventos agudos e letais, como o infarto do miocárdio. Segundo Nascimento et al. (2018), em 2016, a cardiopatia isquêmica consolidou-se como a principal causa específica de morte cardiovascular na maioria dos países de língua portuguesa analisados.

O diagnóstico tradicional dessas condições envolve a avaliação de fatores de risco, como hipertensão, diabetes e tabagismo, o exame clínico detalhado e a análise de exames complementares, como o eletrocardiograma (ECG), exames de sangue e

exames de imagem. No entanto, a complexidade e a multifatorialidade dessas doenças muitas vezes exigem abordagens preditivas mais robustas para antecipar eventos em populações de risco (Organização Mundial da Saúde, 2025).

2.1.1 Classificação das Doenças Cardiovasculares

De acordo com a Organização Mundial da Saúde (2025), as doenças cardiovasculares podem ser categorizadas com base na sua fisiopatologia e nos sistemas anatômicos afetados. Essas classificações são apresentadas na Tabela 2.1.

Tabela 2.1 – Categorias das doenças cardiovasculares, de acordo com a OMS (2025).

Tipo de Doença			Descrição
Doença Arterial Coronariana (DAC)			Envolve os vasos sanguíneos que irrigam o músculo cardíaco. É geralmente causada por aterosclerose e está associada ao infarto do miocárdio.
Doença Cerebrovascular			Afeta os vasos sanguíneos que irrigam o cérebro. O comprometimento deste fluxo pode levar a Acidentes Vasculares Cerebrais (AVC), sejam isquêmicos ou hemorrágicos.
Doença Arterial Periférica			Caracteriza-se pela doença dos vasos sanguíneos que irrigam os membros superiores e inferiores, reduzindo o fluxo sanguíneo para essas extremidades.
Doença Cardíaca Reumática			Refere-se a danos causados ao músculo do coração e às válvulas cardíacas resultantes da febre reumática, uma resposta inflamatória autoimune a infecções causadas por bactérias estreptocócicas.
Cardiopatía Congênita			Engloba malformações na estrutura do coração presentes desde o nascimento, podendo afetar o desenvolvimento e o funcionamento cardíaco ao longo da vida.
Trombose Venosa Profunda e Embolia Pulmonar			Consiste na formação de coágulos sanguíneos (trombos) nas veias das pernas, que podem se deslocar (êmbolos) e obstruir vasos vitais no coração ou nos pulmões.

2.1.2 Fatores de Risco

O desenvolvimento das DCV é um processo multifatorial, influenciado por uma combinação de fatores de risco modificáveis e não modificáveis. A identificação e o manejo desses fatores são fundamentais para a prevenção das doenças cardiovasculares. Os fatores de risco podem ser classificados da seguinte forma:

- **Fatores Não Modificáveis:** Incluem idade, sexo, etnia e predisposição genética. Embora não possam ser alterados, seu conhecimento é fundamental para a estratificação de risco individual.
- **Fatores Modificáveis:** Englobam condições fisiológicas e comportamentais que podem ser controladas ou tratadas, como hipertensão arterial, diabetes, dislipidemia, obesidade, tabagismo, sedentarismo, dieta inadequada e consumo excessivo de álcool (NASCIMENTO et al., 2022).

Os estudos de Nascimento et al. (2022) demonstraram que a combinação de hipertensão, diabetes, hipercolesterolemia, obesidade e tabagismo está presente em 80% a 95% dos indivíduos que sofrem um evento cardiovascular.

2.1.3 Análise dos Principais Fatores de Risco Modificáveis

A compreensão profunda das variáveis modificáveis é essencial para este estudo, uma vez que elas compõem o conjunto de características que alimentarão os algoritmos de aprendizado de máquina. Cada fator atua por mecanismos biológicos distintos, mas interligados, para promover o desenvolvimento da patologia cardiovascular.

A hipertensão arterial é considerada um dos mais importantes fatores de risco para doenças cardiovasculares, estando diretamente associada a um aumento significativo na incidência de AVC, DAC, insuficiência cardíaca e doença vascular periférica. O controle adequado da pressão arterial é comprovadamente eficaz na redução desses eventos. É importante destacar que mesmo valores de pressão arterial classificados como pré-hipertensão já indicam um risco cardiovascular elevado (PÓVOA, 2024).

Em relação ao diabetes, adultos acometidos pela doença possuem um risco de duas a quatro vezes maior de desenvolver patologias cardiovasculares em comparação com a população geral, risco este que é amplificado por um controle glicêmico

inadequado. O diabetes está associado a um aumento de 75% na mortalidade geral, sendo as DCV a principal causa desse excesso. A doença contribui tanto para complicações macrovasculares, como DAC e AVC, quanto microvasculares, como doença renal crônica e retinopatia, que, por si só, aumentam o risco cardiovascular (CANTO et al., 2019).

A dislipidemia, caracterizada por níveis anormais de lipídios no sangue, como colesterol de baixa densidade (LDL) elevado, colesterol de alta densidade (HDL) baixo e triglicerídeos elevados, constitui um pilar no desenvolvimento da aterosclerose. O acúmulo de partículas de LDL na parede arterial inicia um processo inflamatório que leva à formação de placas ateroscleróticas, as quais podem restringir o fluxo sanguíneo ou romper-se, causando trombose aguda (NASCIMENTO et al., 2022). Estudos recentes também destacam o papel das apolipoproteínas, como a ApoB, como marcadores de risco mais precisos que as medições lipídicas tradicionais, especialmente em populações mais jovens (BARROSO; SOUZA, 2020).

A obesidade é um fator de risco independente para DCV, além de potencializar outros fatores, como hipertensão, diabetes tipo 2 e dislipidemia. O excesso de tecido adiposo, particularmente a gordura visceral, promove um estado inflamatório crônico e disfunção endotelial. Estima-se que o risco de desenvolver doença cardiovascular ao longo da vida seja até 85% maior em indivíduos com obesidade em comparação com aqueles com peso normal (Sociedade de Cardiologia do Estado do Rio de Janeiro (SOCERJ), 2024; BARROSO; SOUZA, 2020).

O tabagismo acelera o processo de aterosclerose, aumenta a pressão arterial, promove a formação de trombos e reduz a capacidade de transporte de oxigênio do sangue, sendo a cessação do tabaco uma das medidas preventivas mais eficazes. Por sua vez, o sedentarismo contribui para a obesidade e outros fatores de risco metabólicos, além de reduzir a capacidade funcional do coração (Organização Pan-Americana de Saúde, 2025).

Além dos riscos individuais, determinantes sociais como nível socioeconômico, escolaridade, urbanização acelerada e acesso limitado a alimentos saudáveis e cuidados de saúde, somados a fatores ambientais como a poluição do ar, criam um contexto que pode favorecer o desenvolvimento de DCV (Organização Pan-Americana de Saúde, 2025). A abordagem das DCV, portanto, exige não apenas intervenções clínicas individuais, mas também políticas públicas robustas que promovam ambientes mais saudáveis e equitativos.

2.2 Fundamentos da Inteligência Artificial

A Inteligência Artificial (IA) é um campo da ciência da computação voltado ao desenvolvimento de sistemas capazes de simular a inteligência humana, executando tarefas como aprendizado, raciocínio, percepção e tomada de decisões. A IA é uma área multidisciplinar que busca criar máquinas que possam imitar a capacidade de resolução de problemas e cognição humana. A IA pode ser utilizada para auxiliar os seres humanos na tomada de decisões com base no reconhecimento de padrões e na associação de dados históricos (MORAIS et al., 2020).

2.2.1 Características Fundamentais da Inteligência Artificial

A Inteligência Artificial pode ser definida por sua capacidade de:

- **Aprendizado**, que consiste em adquirir conhecimento e regras a partir de dados previamente definidos, identificando, assim, padrões e relações
- **Raciocínio**, que tem como objetivo aplicar lógica e inferência para tomar decisões
- **Adaptação**, que, ao longo do período, passa por ajustes e melhorias de desempenho com base em novas experiências e dados.

2.3 *Machine Learning*

O *Machine Learning* (ML), também chamado de Aprendizado de Máquina, é um subcampo da IA que se concentra no desenvolvimento de algoritmos que permitem aos computadores aprender a partir de dados, sem serem explicitamente programados para cada tarefa. O ML utiliza modelos estatísticos para analisar dados, identificar padrões e fazer previsões ou classificações. Os algoritmos de ML podem ser classificados em três categorias:

- **Aprendizado Supervisionado:** Utiliza dados de treinamento rotulados, onde cada entrada está associada a uma saída conhecida. O algoritmo aprende a mapear a entrada para a saída, sendo ideal para tarefas de classificação e regressão (PAIXÃO et al., 2022);

- **Aprendizado Não Supervisionado:** Utiliza dados de treinamento não rotulados, buscando descobrir estruturas e padrões nos dados sem uma saída predefinida. Geralmente, utilizado para aplicação em técnicas de agrupamento e associação (PAIXÃO et al., 2022);
- **Aprendizado Profundo (*Deep Learning*):** Utiliza redes neurais com múltiplas camadas para aprender representações de dados em diferentes níveis de abstração, sendo a base para avanços em reconhecimento de fala e visão computacional (PACHECO, 2018).

2.4 Algoritmos de *Machine Learning*

Os algoritmos de ML desempenham um papel fundamental na construção de modelos capazes de identificar padrões nos dados e realizar previsões de forma automatizada. Esses métodos permitem que sistemas computacionais aprendam as relações presentes em conjuntos de dados e tomem decisões com base nesses padrões, cada um apresentando características próprias e abordagens específicas para a tarefa de classificação. Nesta seção, serão apresentados os conceitos dos algoritmos de aprendizado supervisionado, incluindo Regressão Logística, *Support Vector Machine*, Árvore de Decisão e *K-Nearest Neighbors*.

2.4.1 Regressão Logística

A Regressão Logística é um dos métodos estatísticos mais tradicionais e amplamente utilizados para problemas de classificação binária, fundamentada na modelagem da probabilidade de ocorrência de um evento por meio da função logística. Diferentemente dos modelos lineares tradicionais, a regressão logística aplica a transformação *logit* para relacionar as variáveis independentes à probabilidade do desfecho, garantindo que os valores previstos permaneçam no intervalo entre 0 e 1. Essa técnica é reconhecida por sua interpretabilidade, eficiência computacional e desempenho consistente, mesmo em cenários com relações moderadamente lineares entre as variáveis (HOSMER; LEMESHOW; STURDIVANT, 2013). A regressão logística tem sido consolidada como uma ferramenta essencial na estatística aplicada, aprendizado de máquina e áreas como medicina, epidemiologia e ciências sociais.

A principal vantagem da Regressão Logística em relação à regressão linear tradicional reside em sua capacidade de lidar adequadamente com variáveis depen-

dentos binárias. Enquanto modelos lineares podem gerar previsões fora do intervalo lógico, a regressão logística fornece interpretações probabilísticas diretas, permitindo entender não apenas a classe de pertencimento, mas também a confiança dessa previsão. Além disso, o modelo oferece coeficientes interpretáveis que, quando convertidos em razão de chances (*odds ratio*), elucidam a intensidade e a direção do efeito de cada fator de risco sobre o desfecho clínico (JAMES et al., 2023).

Matematicamente, a relação entre as variáveis independentes e a probabilidade do evento de interesse é expressa pela função logística. Considerando que a previsão de doenças cardiovasculares envolve múltiplos fatores de risco, utiliza-se a formulação da Regressão Logística Múltipla.

Seja Y a variável resposta binária (onde $Y = 1$ indica a presença da doença) e $X = (X_1, X_2, \dots, X_k)$ o vetor composto por k variáveis preditoras (como idade, colesterol, pressão arterial, etc.), a probabilidade $p(X) = Pr(Y = 1|X)$ é dada pela Equação 2.1:"

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}} \quad (2.1)$$

Onde β_0 é o intercepto e $\beta_1, \dots, \beta_k$ são os coeficientes de regressão estimados para cada uma das k variáveis independentes do modelo. Essa estrutura permite avaliar o impacto simultâneo de múltiplos preditores na probabilidade do desfecho.

A partir desta formulação, aplica-se a transformação *logit* para linearizar a relação entre os preditores e o desfecho, conforme a Equação 2.2:

$$\ln \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k \quad (2.2)$$

A expressão à esquerda ($\ln(\frac{p}{1-p})$) representa o *log-odds*. Note que, diferentemente da regressão linear simples, este modelo soma os efeitos ponderados ($\beta_k X_k$) de todas as variáveis clínicas consideradas, permitindo calcular como o logaritmo da chance de doença varia em função do conjunto de características do paciente.

Para a estimação dos coeficientes β apresentados nas equações anteriores, a regressão logística não utiliza o método dos Mínimos Quadrados Ordinários, tradicional na regressão linear. Em vez disso, adota-se o método da Máxima Verossimilhança (*Maximum Likelihood*). O objetivo deste método é encontrar o conjunto de parâmetros que maximiza a probabilidade (verossimilhança) de observar os dados amostrais que foram efetivamente coletados. Como não existe uma solução algébrica fechada para essa maximização na regressão logística, são utilizados algoritmos numéricos iterativos para a convergência dos parâmetros ótimos (JAMES et al., 2023).

2.4.2 Support Vector Machine

O *Support Vector Machine* (SVM) é um algoritmo reconhecido por sua capacidade de realizar classificações de alta precisão, especialmente em problemas com fronteiras complexas. Proposto por Cortes e Vapnik, o SVM busca encontrar o hiperplano que maximiza a margem entre as classes, garantindo maior separabilidade e melhor capacidade de generalização. Apenas um subconjunto dos dados, denominado vetores de suporte, contribui para a definição dessa fronteira, o que torna o modelo eficiente e menos sensível a ruídos (CORTES; VAPNIK, 1995).

Para lidar com a não linearidade típica de dados médicos, o SVM utiliza uma abordagem baseada em *Kernels*. Conforme detalham James et al. (2023), essa técnica permite ampliar o espaço de características para acomodar fronteiras não-lineares de forma computacionalmente eficiente, calculando apenas os produtos internos entre as observações. A função de decisão para classificar uma nova observação x é dada pela Equação 2.3:

$$f(x) = \beta_0 + \sum_{i \in S} \alpha_i K(x, x_i) \quad (2.3)$$

Onde β_0 é o intercepto (viés), S representa o conjunto de índices dos vetores de suporte e α_i são os parâmetros estimados. O termo $K(x, x_i)$ é a função de *kernel*, que substitui o produto interno linear por uma medida de similaridade mais complexa.

Considerando os fatores de risco cardiovasculares, utiliza-se frequentemente o *Kernel Radial* (RBF), cuja formulação permite modelar fronteiras de decisão locais e curvas suaves. Sua definição matemática é apresentada na Equação 2.4:

$$K(x_i, x_{i'}) = \exp \left(-\gamma \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right) \quad (2.4)$$

Nesta função, γ é um hiperparâmetro positivo que controla a influência de uma única observação de treinamento. Se γ for muito alto, o modelo se ajusta excessivamente aos dados (*overfitting*); se for muito baixo, o modelo pode se tornar rígido demais. A escolha correta do *kernel* e de seus parâmetros é determinante para o sucesso da classificação em cenários onde a separação linear é insuficiente (JAMES et al., 2023).

2.4.3 Árvores de Decisão

As árvores de decisão são métodos não paramétricos que podem ser aplicados tanto em problemas de regressão quanto em problemas de classificação. A lógica deste algoritmo consiste em estratificar ou segmentar o espaço de preditores em um número de regiões simples e distintas. Para realizar uma predição em uma nova observação, o critério varia conforme o objetivo do modelo, ou seja, em problemas de regressão, atribui-se a média ou mediana dos valores de resposta das observações e do treinamento pertencentes naquela região, e em problemas de classificação, atribui-se a moda entre as observações da região estratificada (JAMES et al., 2023).

Na visualização da estrutura, o modelo assemelha-se a um fluxograma invertido, composto por nós (ou folhas), por isso surge o nome de árvore. O ponto inicial é o nó raiz, que contém toda a amostra. A partir dele, aplicam-se regras de decisão baseadas nos valores das variáveis preditoras, bifurcando os dados em nós internos até atingir nós terminais, onde a decisão final é tomada. Essa estrutura hierárquica se assemelha ao raciocínio humano, oferecendo alta interpretabilidade para diagnósticos médicos.

Do ponto de vista computacional, a construção da árvore é realizada através de um processo conhecido como divisão binária recursiva (*recursive binary splitting*). Segundo James et al. (2023), esta é uma abordagem gulosa (*greedy*) e descendente (*top-down*), que busca, em cada etapa, a melhor divisão possível naquele momento específico, sem considerar passos futuros. Para determinar a qualidade de uma divisão em problemas de classificação, utiliza-se frequentemente o Índice Gini, que avalia a pureza total de um nó.

Definindo $\hat{p}_{mk}$ como a proporção de observações de treinamento na m -ésima região que pertencem à k -ésima classe, o Índice Gini (G) é dado pela Equação 2.5:

$$G = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk}) \quad (2.5)$$

Onde K representa o número total de classes (no caso de predição de doença cardiovascular, $K = 2$, correspondendo a presença ou ausência da condição). O Índice Gini assume um valor pequeno se todas as proporções $\hat{p}_{mk}$ estiverem próximas de zero ou de um. Portanto, este índice atua como uma medida de variabilidade ou impureza do nó, quanto menor o valor de G , mais puro é o nó, indicando que a região contém predominantemente observações de uma única classe (JAMES et al., 2023).

Uma alternativa ao Índice Gini é a Entropia (D), fundamentada na teoria da informação, expressa na Equação 2.6:

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log(\hat{p}_{mk}) \quad (2.6)$$

Assim como o Gini, a Entropia (D) será mínima se o nó for puro. O algoritmo avalia todas as divisões possíveis em todos os preditores e escolhe aquela que resulta na maior redução dessa impureza. Embora as árvores de decisão sejam altamente interpretáveis e fáceis de visualizar, elas podem sofrer de alta variância e *overfitting* se crescerem indefinidamente, razão pela qual o ajuste de hiperparâmetros é essencial para garantir a generalização do modelo.

2.4.4 *K-Nearest Neighbors*

O *K-Nearest Neighbors* (KNN) é um algoritmo não paramétrico que pode ser aplicado tanto a problemas de classificação quanto para regressão. Diferentemente de métodos baseados em modelos, como ocorre na regressão logística, o KNN não estima coeficientes para ajustar dados a uma forma pré-definida. Ao contrário disso, ele memoriza o conjunto de treinamento e realiza previsões para uma nova observação baseando-se na similaridade com os dados vizinhos no espaço de características (JAMES et al., 2023).

O funcionamento do algoritmo se baseia na identificação das K observações de treinamento mais próximas ao ponto de teste x_0 . Seja $\mathcal{N}_0$ o conjunto que contém esses K vizinhos. O KNN estima a probabilidade condicional de a observação pertencer à classe j como a fração de pontos em $\mathcal{N}_0$ que pertencem a essa classe, conforme a Equação 2.7:

$$P(Y = j | X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} I(y_i = j) \quad (2.7)$$

Onde $I(y_i = j)$ é uma função indicadora que retorna 1 se a classe do vizinho y_i for igual a j , e 0 caso contrário. Após calcular essa probabilidade, o algoritmo aplica a regra de decisão de *Bayes*, classificando a observação x_0 na classe que obtiver a maior probabilidade. Ao aplicar essa regra sistematicamente a todo o espaço de características, o algoritmo estabelece efetivamente uma fronteira de decisão que separa as classes (JAMES et al., 2023).

Para definir quais observações são vizinhas, é necessário estabelecer uma métrica de distância. Em aplicações médicas com variáveis contínuas, a métrica mais

comum é a Distância Euclidiana. Dado dois pontos x_a e x_b em um espaço com p variáveis (preditores), a distância é calculada pela Equação 2.8:

$$d(x_a, x_b) = \sqrt{\sum_{j=1}^p (x_{aj} - x_{bj})^2} \quad (2.8)$$

É fundamental ressaltar que, como o KNN depende diretamente de distâncias, as variáveis preditoras devem ser previamente padronizadas. Sem isso, variáveis com grandes magnitudes numéricas dominariam o cálculo da distância em relação a variáveis de menor magnitude, enviesando a classificação.

A escolha do hiperparâmetro K exerce influência crítica no desempenho do modelo. Segundo James et al. (2023), um valor muito pequeno de K (ex: $K = 1$) resulta em fronteiras de decisão excessivamente flexíveis e recortadas, levando a alta variância e *overfitting*. Por outro lado, um valor muito grande de K suaviza a fronteira de decisão, reduzindo a variância, mas aumentando o viés, o que pode mascarar padrões locais importantes para o diagnóstico.

3. TRABALHOS RELACIONADOS

Paixão et al. (2022) apresenta uma revisão sistemática sobre o uso de Machine Learning na medicina, com o objetivo de introduzir seus conceitos fundamentais aos profissionais de saúde e discutir sua aplicabilidade clínica, com ênfase particular nas inovações em cardiologia. Nesse sentido, o artigo não se limita à proposição de um modelo específico, mas consolida o conhecimento sobre técnicas e modelos de aprendizado, como supervisionados e não supervisionados, servindo como fundamentação teórica para aplicações prognósticas e diagnósticas já documentadas na literatura.

A metodologia empregada pelos autores caracteriza-se por uma revisão sistemática da literatura, utilizando as bases de dados *PubMed* e *Medline* e selecionando estudos prospectivos e retrospectivos mediante a avaliação de dois investigadores. O artigo descreve as etapas dos algoritmos de *machine learning*, como o pré-processamento, o treinamento e a avaliação, e revisa os principais algoritmos utilizados, como redes neurais artificiais, regressão logística, árvore de decisão, *random forests*, redes *bayesianas*, *deep learning* e *support vector machines*.

Os resultados da revisão demonstraram um crescimento exponencial na produção científica sobre *machine learning* na medicina, com um aumento significativo no número de artigos publicados ao longo dos anos, evidenciando a relevância e o interesse crescente da área. O estudo destaca a aplicabilidade do ML em diversas especialidades médicas, com ênfase em cardiologia, onde as técnicas de ML tem sido utilizadas com sucesso no prognóstico, diagnóstico e tratamento das doenças. Os autores ressaltam que os modelos de ML, ao analisarem *big data* e variáveis não tradicionais, conseguem identificar pacientes em risco que poderiam ser negligenciados pelas ferramentas convencionais de estratificação de riscos.

O estudo possui uma natureza didática e abrangente, que cumpre com excelência o objetivo de ser uma introdução ao *machine learning* para profissionais de saúde. O artigo consegue traduzir conceitos completos de ML, como a diferença entre aprendizado supervisionado e não supervisionado e o funcionamento das redes neurais, para uma linguagem acessível, sem perder o rigor técnico. Essa característica o torna um ponto de partida fundamental para qualquer pesquisador que deseje iniciar os estudos ou aplicações de ML na área da saúde, fornecendo tanto um panorama técnico quanto exemplos práticos de sua aplicação com foco na cardiologia.

Costalat e Tavares (2022) apresenta uma alternativa para a detecção de doenças cardiovasculares baseada em inteligência artificial, com o objetivo de avaliar a eficácia de diferentes algoritmos de aprendizado supervisionado na predição de riscos

cardíacos a partir de indicadores de saúde, como idade, sexo, glicose e colesterol. A relevância do estudo consiste no fato de que as doenças cardiovasculares são uma das principais causas de morte no mundo, o que torna essencial identificar a melhor alternativa para a construção de um preditor eficaz para auxiliar na prevenção e no manejo de pacientes em alto risco.

A metodologia empregada no estudo baseou-se na utilização do *Heart Disease Data Set*, disponível no Repositório *UCI Machine Learning*. Este banco de dados contém 14 atributos utilizados no estudo para um total de 303 indivíduos. Foram implementados e comparados quatro algoritmos de aprendizado supervisionado: *K-Nearest Neighbours*, árvore de decisão, regressão logística e o *voting classifier*. A implementação foi realizada utilizando a linguagem de programação Python e a biblioteca *Scikit-learn*. A avaliação dos modelos foi realizada por meio de uma metodologia de teste que inclui a análise da acurácia, sensibilidade e especificidade, com base na matriz de confusão de cada classificador.

Os resultados da comparação demonstram que o *voting classifier* alcançou a maior acurácia entre os modelos testados, atingindo um valor de 82,89%. Isoladamente, os algoritmos de regressão logística e KNN apresentaram o mesmo desempenho, ambos com acurácia de 80,26%. Já a árvore de decisão obteve o desempenho mais baixo, com acurácia de 73,68%. O desempenho superior do *voting classifier* sugere que a combinação de diferentes modelos de ML pode mitigar as fraquezas individuais de cada algoritmo, resultando em um preditor mais robusto e confiável para a detecção de doenças cardiovasculares.

Vale destacar a validação da abordagem *ensemble* proposta pelos autores. Ao demonstrar que o *voting classifier* superou as técnicas de desempenho de um único algoritmo, o trabalho reforça a ideia de que a combinação de múltiplos algoritmos é uma estratégia viável e superior para mitigar limitações de modelos únicos. Essa conclusão é valiosa para a área de diagnóstico médico auxiliado por ML, pois sugere um caminho claro para aumentar a confiabilidade e a capacidade preditiva na identificação de pacientes em risco.

Oliveira, Ferreira e Barreiros (2023) apresenta uma análise comparativa de algoritmos de *machine learning* na tarefa de classificar o estado de saúde de pacientes em relação à predisposição para doenças cardiovasculares. Reconhecendo que as doenças cardiovasculares são a principal causa de morte e são frequentemente silenciosas, os autores propuseram o uso de ML para agilizar e simplificar o diagnóstico prévio, reduzindo a intervenção humana em análises complexas. Para isso, o estudo aplicou e avaliou três modelos distintos de classificação em um conjunto de dados pú-

blicos de pacientes, buscando identificar o modelo mais eficiente para a classificação binária de presença ou ausência de doença cardiovascular.

Metodologicamente, o estudo implementou os algoritmos K-Nearest Neighbor, árvore de decisão e rede neural multicamada perceptron (MLP), utilizando a linguagem *python*, o ambiente *Google Colab* e as bibliotecas *scikit-learn* e *pandas* para a implementação e manipulação dos dados. A base de dados pública utilizada foi a *heart.csv*, sobre doenças cardiovasculares, contendo informações de 1025 pacientes e 13 características biológicas, como idade, sexo, tipo de dor no peito e colesterol. Antes da aplicação dos modelos, os dados passaram por um pré-processamento que incluiu a normalização e a utilização da técnica de validação cruzada *K-Fold* (com 3 *folds*) para mitigar o risco de *overfitting*. A avaliação de desempenho foi realizada com base em métricas estatísticas como *Precision*, *Recall*, *F1-score* e *Support*.

Os resultados da análise comparativa demonstraram que a árvore de decisão foi o algoritmo com o melhor desempenho, apresentando uma precisão superior a 0,96 e um *F1-score* médio de 0,97 para ambas as classes (saudável e com doença cardiovascular). O algoritmo KNN também obteve resultados consideráveis, com um *F1-score* médio de 0,88, indicando sua adequação para problemas de classificação mais simplificados. Por outro lado, a Rede MLP apresentou desempenho mais baixo entre os três, com um *F1-score* médio de 0,80, apesar de utilizar técnicas de otimização como o *backpropagation*.

Vale ressaltar que o desempenho inferior da Rede MLP neste cenário específico está associado às características da base de dados utilizada, uma vez que arquiteturas baseadas em *backpropagation* geralmente exigem um volume de dados massivo e um maior custo computacional para calibrar seus pesos adequadamente. Assim, embora a árvore de decisão tenha se provado o algoritmo mais robusto para o conjunto de dados atual, a exploração completa do potencial de modelos mais complexos, como as redes neurais, depende da ampliação dos registros clínicos em pesquisas futuras, garantindo uma diversidade amostral que favoreça o aprendizado profundo.

Ferreira, Almeida e Castilho (2025) apresenta um mapeamento sistemático da literatura sobre o uso de algoritmos de machine learning na previsão de doenças cardiovasculares, com o objetivo de sintetizar o conhecimento sobre as técnicas eficazes para o diagnóstico precoce dessas condições. Os autores realizaram uma investigação abrangente sobre diversos artigos que aplicam técnicas de ML, com foco na comparação de desempenho entre modelos de *ensemble*, *Deep Learning* e algoritmos tradicionais, como *Random Forest*, *Support Vector Machines* e redes neurais. O objetivo foi determinar quais metodologias se destacam em termos de eficiência

e acurácia para o diagnóstico precoce de doenças cardiovasculares, um fator crucial para a redução da alta taxa de mortalidade global associada a essas condições.

A metodologia empregada para a realização deste estudo foi o mapeamento sistemático, um método rigoroso que visa fornecer uma visão abrangente de uma área de conhecimento. O processo envolveu a definição de questões de pesquisa específicas, a formulação de termos de busca detalhados e a aplicação de critérios de inclusão e exclusão bem definidos. A busca foi realizada nas bases de dados *IEEE Xplore* e *Scopus*, resultando em uma seleção inicial de 90 trabalhos. Após uma filtragem em três etapas (busca inicial, filtragem por título e resumo, e leitura completa), apenas 14 artigos foram selecionados para a análise final, garantindo que apenas estudos que comparavam a eficiência de modelos de ML na previsão de doenças cardiovasculares fossem considerados.

Os resultados do mapeamento sistemático revelaram que os modelos híbridos e as técnicas de *Deep Learning* apresentam os mais altos níveis de acurácia na previsão de doenças cardiovasculares. Modelos de *ensemble*, como o *stacking* e o uso de *Gradient Boosting* como *meta-learner*, demonstraram ser particularmente promissores. Notavelmente, um modelo híbrido de *Hybrid Deep Neural Networks* (HDNNs) que combinou *Convolutional Neural Network* (CNN) e *Long Short-Term Memory* (LSTM) alcançou uma acurácia impressionante de 98,86%. Entre os algoritmos tradicionais, o *Random Forest* se manteve como um dos mais citados e eficientes, reforçando sua robustez e aplicabilidade na área.

Apesar da alta precisão alcançada, o trabalho destaca barreiras significativas, como a necessidade de maior qualidade e disponibilidade de dados, a importância da seleção de características e, principalmente, a questão da interpretabilidade. Modelos mais complexos, como as *Deep Neural Networks*, são frequentemente vistos como "caixas-pretas", o que dificulta sua adoção na prática médica. O estudo conclui que é essencial buscar uma maior integração entre a alta acurácia, a interpretabilidade e a usabilidade para que o *Machine Learning* possa ser amplamente incorporado no contexto clínico de previsão de doenças cardiovasculares.

3.1 Lacuna de Pesquisa

A análise dos trabalhos relacionados apresentados no Capítulo 3 evidencia que, embora existam avanços consistentes no uso de técnicas de aprendizado de máquina e aprendizado profundo aplicadas ao domínio investigado neste Trabalho de Conclusão de Curso, ainda permanecem lacunas relevantes que justificam a realiza-

ção desta pesquisa. De modo geral, os estudos analisados concentram-se na proposição e avaliação de modelos sob conjuntos de dados específicos, frequentemente limitados a contextos controlados, com pouca discussão acerca da generalização das soluções propostas ou de sua adaptação a cenários distintos daqueles considerados nos experimentos originais.

Observa-se também que uma parte significativa das pesquisas prioriza a comparação entre arquiteturas ou algoritmos isolados, sem uma análise aprofundada dos impactos das etapas de preparação dos dados, das escolhas metodológicas ou das restrições impostas pelo ambiente de aplicação. Em vários trabalhos, aspectos como a integração prática da solução desenvolvida, a análise das limitações operacionais e a reprodutibilidade dos experimentos recebem atenção secundária, o que dificulta a consolidação do conhecimento produzido e sua aplicação em contextos reais.

Nesse sentido, a lacuna de pesquisa explorada neste trabalho situa-se na necessidade de uma abordagem que articule, de forma coerente, a fundamentação teórica, o tratamento sistemático dos dados e a modelagem computacional, considerando as particularidades do problema investigado e as limitações identificadas na literatura. Ao direcionar o foco para essa articulação, este estudo busca contribuir para a ampliação da compreensão sobre o tema, oferecendo uma análise alinhada às demandas acadêmicas e práticas, e complementando os resultados apresentados nos trabalhos correlatos.

4. METODOLOGIA

A presente pesquisa caracteriza-se como um estudo de natureza aplicada, com abordagem quantitativa e caráter experimental. O objetivo é desenvolver e avaliar modelos computacionais baseados em aprendizado de máquina para a predição de doenças cardiovasculares, seguindo um fluxo de trabalho de ciência de dados que compreende a definição e coleta de dados, pré-processamento, modelagem e avaliação de desempenho. A metodologia proposta baseia-se nas práticas observadas na revisão da literatura.

Para a execução deste estudo, será utilizada a base de dados MIMIC-IV, um recurso de acesso público, amplo e anonimizado que contém dados de saúde de pacientes admitidos em unidades de terapia intensiva (UTI) do *Beth Israel Deaconess Medical Center*, em Boston, Massachusetts. Este *dataset* é amplamente reconhecido na comunidade científica por sua alta granularidade e abrangência, incluindo informações demográficas, sinais vitais, resultados de exames laboratoriais, medicamentos, diagnósticos codificados, entre outros. A seleção de pacientes para este trabalho se concentrará em indivíduos com diagnóstico primário de doenças cardiovasculares, como infarto agudo do miocárdio, insuficiência cardíaca e doença isquêmica crônica do coração, a fim de construir um conjunto de dados coeso e relevante para o objetivo proposto.

A seleção das variáveis para a construção dos modelos preditivos foi fundamentada em uma extensa revisão da literatura sobre fatores de risco e biomarcadores associados a eventos cardiovasculares, bem como na disponibilidade e qualidade dos dados no MIMIC-IV.

As variáveis escolhidas abrangem diferentes dimensões da condição clínica do paciente e foram organizadas em grupos específicos para melhor análise. Na categoria Demográfica, consideram-se a idade e o sexo. A dimensão Hemodinâmica engloba a pressão arterial (sistólica e diastólica) e a frequência cardíaca. No que tange aos Biomarcadores Cardíacos, são analisados a Troponina (I ou T) e o Peptídeo Natriurético (BNP ou NT-proBNP). A avaliação Laboratorial Geral é composta por creatinina e ureia, hemograma completo (incluindo hemoglobina e leucócitos), eletrólitos (sódio e potássio) e o perfil lipídico (colesterol total, HDL e LDL). Por fim, os dados provenientes do Eletrocardiograma (ECG) observam as anormalidades no segmento ST e Onda T, bem como a duração do complexo QRS.

O tratamento dos dados brutos é uma etapa crítica para garantir a qualidade e a confiabilidade dos modelos de aprendizado de máquina. O pré-processamento dos dados será realizado em várias etapas. Primeiramente, será feita a identifica-

ção e o tratamento de valores ausentes. Dependendo da natureza e da proporção de dados faltantes para cada variável, serão empregadas estratégias como a imputação pela média ou mediana para variáveis numéricas contínuas, ou a remoção de registros caso a quantidade de informações ausentes seja impeditiva para uma análise consistente. Em seguida, será realizada a detecção e o tratamento de valores atípicos, que podem distorcer o treinamento dos modelos. Para isso, serão utilizados métodos estatísticos como o intervalo interquartil, e os valores discrepantes serão ajustados ou removidos conforme a análise de seu impacto. Por fim, as variáveis numéricas independentes serão normalizadas por meio da técnica de *Z-score*, que transforma os dados para que tenham média zero e desvio padrão de um. Esse procedimento é essencial para algoritmos sensíveis à escala das variáveis, garantindo que todas contribuam de forma equilibrada para o processo de modelagem.

Para a etapa de modelagem, serão explorados diferentes algoritmos de aprendizado de máquina supervisionado, selecionados com base em sua popularidade e eficácia comprovada em problemas de classificação no domínio da saúde. Entre os modelos a serem treinados e avaliados estão Regressão Logística, *Support Vector Machine*, Árvores de Decisão e *K-Nearest Neighbors*.

A avaliação de modelos de *Machine Learning* constitui uma etapa fundamental no ciclo de vida do desenvolvimento de sistemas de aprendizado de máquina. Seu propósito inicial é fornecer informações essenciais na tomada de decisões, permitindo determinar o desempenho de um modelo em relação aos requisitos e objetivos específicos do problema.

Para garantir uma avaliação íntegra e representativa, é fundamental particionar o *dataset*, assegurando que os exemplos destinados ao teste sejam distintos daqueles aplicados no treinamento. Por isso, os dados são divididos em três subconjuntos:

- **Treinamento:** Utilizado para o aprendizado dos padrões pelo modelo, compreendendo cerca de 50% do total de dados;
- **Validação:** Destinado ao ajuste de hiperparâmetros e monitoramento de *overfitting* durante o treino, representando aproximadamente 20% dos dados;
- **Teste:** Mantido totalmente isolado do treinamento e utilizado exclusivamente para calcular as métricas finais de desempenho, compondo os 30% restantes.

Para mitigar os riscos de *overfitting* e garantir que as métricas de desempenho não sejam resultado de um viés na separação dos dados, será utilizada a técnica

de Validação Cruzada *K-Fold* (*K-Fold Cross-Validation*). Este método divide o conjunto de dados em K partes (ou dobras) iguais. O processo de treinamento e avaliação é repetido K vezes, e a cada iteração, uma dobra diferente é reservada para teste, enquanto as K-1 restantes são usadas para treino. A performance final do modelo é dada pela média das métricas obtidas em todas as iterações, fornecendo uma estimativa estatisticamente mais robusta de sua capacidade de generalização.

A avaliação de desempenho de modelos de classificação fundamenta-se na análise de seus erros e acertos. Visto que uma predição pode ser classificada como verdadeira ou falsa, essa análise é estruturada através da Matriz de Confusão, que decompõe os resultados em quatro categorias distintas:

- **True Positive (TP) ou verdadeiro positivo:** O modelo prediz corretamente uma instância como positiva (TEODORO et al., 2025);
- **True Negative (TN) ou verdadeiro negativo:** O modelo prediz corretamente uma instância como negativa (TEODORO et al., 2025);
- **False Positive (FP) ou Falso Positivo:** O modelo prediz erroneamente uma instância como positiva, quando ela é negativa, ou seja o modelo fez uma predição falsamente como positiva (TEODORO et al., 2025);
- **False Negative (FN) ou Falso Negativo:** O modelo prediz erroneamente uma instância como negativa, quando ela é positiva, ou seja o modelo fez uma predição falsamente como negativa (TEODORO et al., 2025).

		Predição	
		Positive	Negative
Real	Positive	TP	FN
	Negative	FP	TN

Tabela 4.1 – Matriz de Confusão
Fonte: O autor

O método padrão para avaliar um modelo de classificação é medir a taxa de erros ou a taxa de acertos (acurácia) em um dataset de teste. A taxa de erros e acertos é calculada a partir da matriz de confusão:

$$\text{taxa de erros} = \frac{FP + FN}{(TP + TN + FP + FN)} \quad (4.1)$$

$$\text{taxa de acertos} = \frac{TP + TN}{(TP + TN + FP + FN)} \quad (4.2)$$

A acurácia, frequentemente referida como taxa de acerto, é uma métrica que expressa a proporção de predições corretas (tanto positivas quanto negativas) em relação ao total de instâncias avaliadas. Em suma, ela indica o desempenho global do modelo ao quantificar o percentual de classificações realizadas corretamente (TEODORO et al., 2025)

A Precisão avalia a confiabilidade das predições positivas feitas pelo modelo. Ela mensura a proporção de exemplos classificados como positivos que são, de fato, verdadeiros, indicando a capacidade do sistema em evitar a classificação incorreta de observações negativas como positivas (minimizando falsos positivos) (TEODORO et al., 2025).

$$precision = \frac{TP}{(TP + FP)} \quad (4.3)$$

O *Recall* (ou Revocação) demonstra a sensibilidade do modelo em recuperar todas as instâncias de interesse. Ele indica a proporção de exemplos positivos reais que foram corretamente identificados, evidenciando a capacidade do sistema em não deixar ocorrências reais passarem despercebidas (minimizando falsos negativos) (TEODORO et al., 2025).

$$recall = \frac{TP}{(TP + FN)} \quad (4.4)$$

A escolha entre priorizar a Precisão ou o *Recall* depende do contexto do problema. Em cenários médicos, por exemplo, o *Recall* tende a ser a métrica de maior interesse, uma vez que as consequências de falhar na detecção de uma patologia existente (falso negativo) são, via de regra, mais severas do que as de um alerta falso.

Segundo Sokolova e Lapalme (2009), o *F1-Score* é uma métrica que combina a Precisão e o *Recall* em um único valor, calculado por meio da média harmônica entre ambos. Diferente da média aritmética simples, essa abordagem penaliza valores extremos; ou seja, para que o *F1-Score* seja alto, tanto a Precisão quanto o *Recall* precisam apresentar um bom desempenho simultaneamente. Essa característica torna o *F1-Score* uma métrica robusta, especialmente em cenários de classes desbalanceadas, onde se busca um equilíbrio entre a qualidade das predições positivas e a abrangência na detecção dos casos de interesse.

$$F1-Score = 2 \cdot \frac{precision \cdot recall}{(precision + recall)} \quad (4.5)$$

Além das métricas como Acurácia, *Recall*, *Precision* e *F1-Score*, a avaliação de modelos médicos exige a análise de desempenho sob diferentes limiares de deci-

são. Para isso, utiliza-se a curva ROC (*Receiver Operating Characteristic*) e a métrica AUC (Área Sob a Curva).

A curva ROC é uma representação gráfica que ilustra a capacidade diagnóstica de um classificador binário conforme o seu limiar de discriminação varia. O gráfico plota duas taxas fundamentais em eixos opostos:

- **Eixo Y (Sensibilidade ou *Recall*):** A capacidade do modelo de detectar corretamente os casos positivos (doentes);
- **Eixo X (Especificidade):** Também conhecida como Taxa de Falsos Positivos (FPR), representa a proporção de casos negativos (saudáveis) incorretamente classificados como doentes.

O cálculo da Taxa de Falsos Positivos (FPR) é dado por:

$$FPR = \frac{FP}{(TN + FP)} \quad (4.6)$$

Visualmente, quanto mais a curva se aproxima do canto superior esquerdo do gráfico, melhor é o desempenho do modelo, indicando alta sensibilidade e baixa taxa de falsos alarmes.

Derivada dessa curva, a AUC (Área Sob a Curva) resume o desempenho do modelo em um único valor escalar, que representa a área sob a curva ROC. A AUC varia de 0 a 1 e possui uma interpretação probabilística direta: ela indica a probabilidade de o modelo classificar um exemplo positivo aleatório com uma pontuação maior do que um exemplo negativo aleatório.

Segundo Fawcett (2006), a AUC é uma métrica preferível em comparação à acurácia simples em domínios com desbalanceamento de classes, pois sua avaliação é insensível às disparidades na distribuição entre classes positivas e negativas, oferecendo uma medida robusta da separabilidade do modelo.

5. CRONOGRAMA

Tarefa	Ago./25	Set./25	Out./25	Nov./25	Dez./25	Jan./26	Fev./26	Mar./26	Abr./26	Mai./26	Jun./26	Jul./26
TCC I												
Definição do tema	X											
Revisão Bibliográfica	X	X	X	X								
Escrita	X	X	X	X								
Defesa					X							
TCC II												
Pré-Processamento dos datasets						X	X	X	X	X		
Treinamento do modelo						X	X	X	X	X		
Análise e validação de resultados						X	X	X	X	X		
Escrita						X	X	X	X	X	X	
Defesa												X

Tabela 5.1 – Cronograma de tarefas para desenvolvimento do TCC

REFERÊNCIAS BIBLIOGRÁFICAS

BARROSO, W. K. S.; SOUZA, A. L. L. Obesidade, sobrepeso, adiposidade corporal e risco cardiovascular em crianças e adolescentes. *Arquivos Brasileiros de Cardiologia*, v. 115, 2020. Acesso em: 04 dez. 2025. Disponível em: <<https://doi.org/10.36660/abc.20200540>>.

CANTO, E. D. et al. Diabetes as a cardiovascular risk factor: An overview of global trends of macro and micro vascular complications. *European journal of preventive cardiology*, v. 26, p. 25–32, 2019. Acesso em: 04 dez. 2025. Disponível em: <<https://doi.org/10.1177/2047487319878371>>.

CHANG, V. et al. An artificial intelligence model for heart disease detection using machine learning algorithms. *Healthcare Analytics*, v. 2, p. 100016, 2022. Acesso em: 12 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2772442522000016>>.

CORREIA, L. et al. Validação de um algoritmo de inteligência artificial para a predição diagnóstica de doença coronariana: Comparação com um modelo estatístico tradicional. *Arquivos Brasileiros de Cardiologia*, Sociedade Brasileira de Cardiologia - SBC, v. 117, n. 6, p. 1061–1070, Dec 2021. Acesso em: 12 nov. 2025. Disponível em: <<https://doi.org/10.36660/abc.20200302>>.

CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, Springer, v. 20, p. 273–297, 1995. Acesso em: 12 nov. 2025. Disponível em: <<https://doi.org/10.1007/BF00994018>>.

COSTALAT, T. R. M.; TAVARES, G. F. Machine learning techniques comparison for risk assessment of cardiovascular disease development by health indicators / comparação de técnicas de aprendizagem de máquinas para avaliação de risco de desenvolvimento de doença cardiovascular por indicadores de saúde. *Brazilian Journal of Development*, v. 8, p. 6851–6862, jan. 2022. Acesso em: 10 dez. 2025. Disponível em: <<https://doi.org/10.34117/bjdv8n1-462>>.

FAWCETT, T. Introduction to roc analysis. *Pattern Recognition Letters*, v. 27, p. 861–874, 06 2006. Acesso em: 12 nov. 2025. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S016786550500303X>>.

FERREIRA, A.; ALMEIDA, M.; CASTILHO, F. Comparativo de precisão entre algoritmos de machine learning para previsão de doenças cardiovasculares: um mapeamento sistemático. In: *Anais da I Escola Regional de Sistemas de Informação de Mato Grosso*. Porto Alegre, RS, Brasil: SBC, 2025. p. 65–72. ISSN 0000-0000. Acesso em: 10 dez. 2025. Disponível em: <<https://sol.sbc.org.br/index.php/ersimt/article/view/35787>>.

HOSMER, J. D. W.; LEMESHOW, S.; STURDIVANT, R. X. *Applied Logistic Regression*. 3. ed. Hoboken, New Jersey: John Wiley & Sons, 2013. Acesso em: 12 nov. 2025. Disponível em: <<https://dl.icdst.org/pdfs/files4/7751d268eb7358d3ca5bd88968d9227a.pdf>>.

JAMES, G. et al. *An Introduction to Statistical Learning: with Applications in Python*. New York: Springer, 2023. (Springer Texts in Statistics). Acesso em: 04 dez. 2025. Disponível em: <<https://www.statlearning.com/>>.

MORAIS, D. M. G. de et al. O conceito de inteligência artificial usado no mercado de softwares, na educação tecnológica e na literatura científica. *Revista de Educação Profissional e Tecnológica em Debate*, v. 12, n. 2, p. 98 – 109, 2020. Acesso em: 12 nov. 2025. Disponível em: <<https://ojs.ifes.edu.br/index.php/ept/article/download/557/539>>.

NASCIMENTO, B. R. et al. Carga de doenças cardiovasculares atribuível aos fatores de risco nos países de língua portuguesa: Dados do estudo “global burden of disease 2019”. *Arquivos Brasileiros de Cardiologia*, v. 118, p. 1028–1048, 2022. Acesso em: 04 dez. 2025. Disponível em: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC9345142/>>.

NASCIMENTO, B. R. et al. Epidemiologia das doenças cardiovasculares em países de língua portuguesa: Dados do “global burden of disease”, 1990 a 2016. *Arquivos Brasileiros de Cardiologia*, v. 110, 2018. Acesso em: 04 dez. 2025. Disponível em: <<https://doi.org/10.5935/abc.20180098>>.

OLIVEIRA, M. C.; FERREIRA, L. V. B.; BARREIROS, M. de O. Classificação de doenças cardiovasculares utilizando aprendizado de máquina. *Revista Multidebates*, v. 7, 2023. Acesso em: 10 dez. 2025. Disponível em: <<https://revista.faculdadeitop.edu.br/index.php/revista/article/view/563>>.

Organização Mundial da Saúde. *Cardiovascular diseases (CVDs)*. 2025. Acesso em: 10 nov. 2025. Disponível em: <[https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))>.

Organização Pan-Americana de Saúde. *Doenças cardiovasculares*. 2025. Acesso em: 04 dez. 2025. Disponível em: <<https://www.paho.org/pt/topicos/doencas-cardiovasculares>>.

PACHECO, N. S. P. C. A. R. Deep learning conceitos e utilização nas diversas Áreas do conhecimento. *Revista Ada Lovelace*, v. 2, p. 34–49, 2018. Acesso em: 12 nov. 2025. Disponível em: <<https://anais.unievangelica.edu.br/index.php/adalovelace/article/download/4132/2770>>.

PAIXÃO, G. M. de M. et al. Machine learning na medicina: Revisão e aplicabilidade. *Arquivos Brasileiros de Cardiologia*, v. 118, n. 3, p. 550–559, 2022. Acesso em: 12 nov. 2025. Disponível em: <<https://www.scielo.br/j/abc/a/WMgVngCLbYfJrkmC65VFCKp/?lang=pt>>.

PÓVOA, R. Hipertensão e risco cardiovascular: Associação direta com os valores pressóricos. *Arquivos Brasileiros de Cardiologia*, v. 121, 2024. Acesso em: 04 dez. 2025. Disponível em: <<https://abccardiol.org/short-editorial/hipertensao-e-risco-cardiovascular-associacao-direta-com-os-valores-pressoricos/>>.

SINGH, M. et al. Artificial intelligence for cardiovascular disease risk assessment in personalised framework: a scoping review. *eClinical Medicine*, v. 73, p. 102660, Jul.

2024. Acesso em: 12 nov. 2025. Disponível em: <[https://www.thelancet.com/journals/eclinm/article/PIIS2589-5370\(24\)00239-6/fulltext](https://www.thelancet.com/journals/eclinm/article/PIIS2589-5370(24)00239-6/fulltext)>.

Sociedade de Cardiologia do Estado do Rio de Janeiro (SOCERJ). *Manual de Obesidade e Doença Cardiovascular*. 2024. Acesso em: 04 dez. 2025. Disponível em: <https://socerj.org.br/wp-content/uploads/2024/04/Manual_SOCERJ_Obesidade_Doenca_Cardiovascular_Completo_250324.pdf>.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing Management*, v. 45, p. 427–437, 07 2009. Acesso em: 12 nov. 2025. Disponível em: <<https://doi.org/10.1016/j.ipm.2009.03.002>>.

TEODORO, G. G. F. et al. Análise do desempenho de classificadores supervisionados na detecção de fraude em transações por cartões de crédito. *RETEC – Revista de Tecnologias*, v. 18, n. 1, p. 24–39, jan./jun. 2025. Acesso em: 12 nov. 2025. Disponível em: <<https://retec.fatecourinhos.edu.br/index.php/retec/article/view/546>>.